

“词码”作为 token 候选译名

含义、技术边界与传播价值

从“词元”的基本单位，到“词码”的符号、计量与编码意象

核心观点

“词码”不仅可以理解为数字编号，也可以表示按照特定规则划分、彼此可区分、能够排列组合和计数，并可映射为数字编号的语言符号单位。它比“词元”更有现实感，比“语粒”更有工程感，是值得正式讨论的 token 候选译名。

一、官方现状与讨论前提

2026 年 3 月 25 日，全国科学技术名词审定委员会优先推荐“词元”作为人工智能领域 token 的中文名，并面向社会发布试用；最终定名仍将结合常态化审定及社会推广情况确认。因而，“词元”当前具有最强规范基础，但围绕易懂性、技术准确性和实际传播效果的讨论仍有空间。

讨论原则：评价候选译名不能只看初次听感，还要同时考察技术本体、既有术语冲突、衍生词能力、跨模态适用性以及社会传播生命力。

二、“码”的汉语义项为何与 token 高度对应

“码”在现代汉语中并不只表示数字代码。结合号码、筹码、一码事、码放和计量单位等义项，“码”呈现出多层语义，并与 token 的不同功能形成对应。

“码”的义项	汉语实例	与 token 的对应
可识别符号	号码、页码、条码、密码	token 是词表中的离散符号项，并对应唯一编号
可计量或交换单位	筹码、砵码、价码	token 可用于上下文容量、吞吐量和 API 计费
类别或事项单位	一码事、两码事	不同 token 是词表中的不同离散类别
排列与堆叠	码砖、码积木、码放	模型处理的是按照顺序排列的 token 序列
计量单位	长度单位“码”	强化可计数、可度量的现实语感

三、“词码”不必等同于 token ID

严格的模型处理链条需要区分离散符号、整数编号和连续向量：

原始文本 → 词元/词码序列 → 词元/词码编号序列 → 嵌入向量序列 → 模型计算

token 是词表中的离散符号项；token ID 是该符号项在词表中的整数索引；embedding 是由编号查得并参与神经网络计算的连续向量。

“码” 并不必然只指编号：筹码不是筹码上的号码，“两码事” 也不是两个数字代码。因此，只要定义清楚，“词码” 可以指离散符号本身，而“词码编号” 则指其整数索引。

推荐定义：词码（token）是模型按照特定词码化规则，从文本或其他信息中得到的基本离散符号单位。每个词码对应词表中的一个编号，并作为模型输入、输出、序列长度与服务计量的基本单位。

四、“词码”比“词元”多表达了什么

“词元” 主要突出“词或语言材料的基本组成单位”；“词码” 则同时激活了符号、类别、编号映射、计量与排列等现代汉语意象。

词元强调	词码增加的意象
基本单位	规则系统中的可识别符号
术语中性	与数码、编码、号码相连的工程感
构成关系	与筹码、价码相连的计量与交换感
模型处理单位	有序排列、类别区分和编号映射

五、“词码”“语粒”“词元”的功能差异

名称	核心意象	优势	局限
词元	基本单元	规范基础强、技术中性、衍生体系稳定	初次听感较抽象，易误以为等于完整词
词码	编码体系中的离散语言符号/筹码	兼具工程、计量、编号和现实语感	可能与 code 或 token ID 混淆，需要明确定义
语粒	语言颗粒	画面直观，容易解释切分与粒度	容易暗示天然颗粒，正式衍生词较弱

可以将三者理解为不同视角：词元说明技术本体，语粒说明外观和直觉，词码说明该单位在数字系统中如何被识别、编号、排列和计量。

六、为什么“语码”和“语义码”不如“词码”

1. “语码”已有正式语言学含义

“语码”在社会语言学中对应 linguistic code，指语言、方言、语体或语言变体，并形成“语码转换”“语码混合”等成熟术语。若同时用来表示 token，会把整套语言系统与模型中的单个离散单位混为一谈。

2. “语义码”错误前置了语义

token 可能是完整词、子词、标点、空格、字节片段或特殊控制符，并非每个 token 都具有独立、完整的语义。具体语义通常在嵌入和上下文计算中形成。

离散符号 → 编号 → 嵌入 → 上下文表示 → 语义形成

因此，“语义码”更适合描述经过语义量化的专门表示，不宜作为通用 token 的名称。

七、“码元”证明了构词逻辑，但不能直接采用

“码元”从字面上兼具“编码符号”和“基本单元”，似乎非常贴切。但“码元”已经是数字通信领域对应 symbol 的成熟术语，表示具有特定状态或波形的基本信号单位，并与波特率等概念关联。

“码元”不能被 token 再次占用，但它反过来证明了：“码”在中文科技术语中，天然适合表达离散、可区分、可计量的符号单位。“词码”的构词逻辑因此并非牵强附会。

八、建议的“词码”术语体系

英文	候选中文
token	词码
token ID	词码编号
tokenization	词码化
tokenizer	词码器 / 词码化器
token sequence	词码序列
token embedding	词码嵌入

token vocabulary	词表 / 词码表
special token	特殊词码
input / output token	输入 / 输出词码
token budget / usage	词码预算 / 词码用量

实际应用中不必机械重命名全部既有术语。例如 vocabulary 仍可称“词表”，避免“词码表”产生新的理解负担。

九、类似“因特网”到“互联网”的语言演化

新技术进入中文时，常先经历保留英文、音译或专业圈内用语阶段；随着使用扩大，能够直接揭示结构或功能的表意名称往往更容易进入日常语言。“互联网”比“因特网”更直观地呈现了网络之间相互连接的结构。

token 的情形更复杂：它同时是词表项、预测类别、序列单位、计费单位和多模态离散单位，很难由一个高度具象的中文词完整覆盖。但如果未来公众主要通过 AI 计费、上下文窗口、生成速度和算力消耗接触 token，“词码”与数码、编码、筹码、价码和码数形成的认知网络，可能具有较强传播生命力。

语言演化判断：“词元”拥有当前规范优势，但术语的长期生命力仍将接受技术实践、工程使用和大众语言习惯的共同检验。

十、综合评价与使用建议

结合“码”的完整汉语义项，对“词码”的评价应当上调。它不只是 token ID 的形象说法，也可以成为 token 本身的有竞争力候选译名。

- 正式论文、标准和规范：当前仍以“词元 (token) ”为宜。
- 术语研究与公众讨论：可把“词码”作为候选译名明确提出。
- 解释编号映射：区分“词码”和“词码编号”。
- 解释文本切分：可辅以“语粒”比喻。
- 解释计费与容量：可辅以“语言筹码”比喻。

最终结论：词元强调它是模型的基本单位；语粒说明它看起来像什么；词码则解释它在数字系统中怎样存在和运作。若“词码”能够稳定地区分 token 与 token ID，它可能成为兼具技术解释力、现实语感和构词扩展能力的中文候选。

参考资料

来源	资料
全国科学技术名词审定委员会	关于发布试用人工智能领域名词 token 中文名 “词元” 的公告，2026-03-25
中国科学院 / 中国科学报	专家解读 token 中文名为何定为 “词元” ， 2026-03-30
OpenAI	Tokenizer 与 Token 基础说明
语言学名词资料	“语码” 及 “语码转换” 的既有术语含义
数字通信资料	“码元 (symbol) ” 的既有术语含义
本次讨论材料	用户提供的 “码” 字基本释义与详细释义